



概率统计

期末速通版本

作者：WHU-cs 2024 级祝天赐

邮箱 zhutianci@whu.edu.cn



目录

第 1 章 核心分布：直觉与本质	2
1.1 泊松分布 (Poisson Distribution)	2
1.2 泊松分布：二项分布的极限 *	2
1.3 指数分布 (Exponential Distribution)	3
1.4 指数分布：泊松过程的等待时间 *	3
1.5 正态分布 (Normal / Gaussian Distribution)	4
第 2 章 多维随机变量：从点到面	5
2.1 联合、边缘与条件分布	5
2.2 极值分布公式	5
第 3 章 变量代换：怎么求 $Y = g(X)$?	6
3.1 一维变换：万能的分布函数法 (CDF Method)	6
3.2 二维变换的本质：重积分通法	7
3.3 三大经典模型的几何视角	7
第 4 章 条件期望：预测的艺术	10
4.1 核心概念：从“切片”到“函数”	10
4.2 四大性质（解题外挂）	10
4.3 协方差与相关系数：量化关系	11
4.4 五大核心恒等式 (运算律)	11
4.5 方差的展开公式（必考）	12
4.6 “不相关”与“独立”	12
第 5 章 三大核心分布的期望与方差推导	13
5.1 泊松分布 $X \sim P(\lambda)$	13
5.2 指数分布 $X \sim E(\lambda)$	13
5.3 正态分布 $X \sim N(\mu, \sigma^2)$	14
第 6 章 极限定理的基石：两大不等式	16
6.1 Markov 不等式：非负变量的边界	16
6.2 Chebyshev 不等式：波动的控制	16
第 7 章 极限定理：从混沌到秩序	18
7.1 大数定律 (LLN)：稳定性的保证	18
7.2 中心极限定理 (CLT)：万物归宗	18
7.3 CLT 的终极魅力：从布朗运动到高斯白噪声	19
第 8 章 参数估计：侦探的游戏	20
8.1 矩估计 (MoM)：简单粗暴的模仿	20
8.2 极大似然估计 (MLE)：谁的嫌疑最大？	20
8.3 高危考点：均匀分布的 MLE	21
8.4 MLE 的巅峰应用：线性回归	21
8.5 深度思考：为什么偏偏是“平方”？	22

第 9 章 区间估计的前奏：三大抽样分布与枢轴量	24
9.1 正态分布的“拼积木”游戏	24
9.2 通法：如何构造枢轴量？	25
9.3 区间估计的三步走	25
9.4 进阶：双剑合璧——两个正态总体的推断	25
第 10 章 抽样分布：统计量的幕后规律	28
10.1 统计量的评判标准：无偏性	28
10.2 样本均值 \bar{X} ：天选之子	28
10.3 样本方差 S^2 ：为什么是 $n-1$ ？	28
10.4 直观解释：自由度的代价	29
第 11 章 假设检验的内核：决策与风险	30
11.1 设立假设：立靶子的艺术	30
11.2 两类错误：弃真与取伪	30
第 12 章 期末实战刷题（真题改编）	32
12.1 实战演练（请独立完成）	32
12.2 答案与解析	33

第1章 核心分布：直觉与本质

内容提要

- 本章我们不搞题海战术，而是要建立对概率分布的“物理直觉”。为什么是这三个分布？
- 泊松分布：描述“单位时间内来了多少人/发了多少消息/发生了多少次故障”。
- 指数分布：描述“还要等多久下一个人才来”。
- 正态分布：描述“大量微小误差叠加后的总结果”。

1.1 泊松分布 (Poisson Distribution)

笔记 [核心直觉：稀有事件的计数] 想象你在盯着学校门口，假设学生到达是随机的。泊松分布关心的是：在一个固定的时间段内（比如1小时），到底来了几个人？

它常用于描述稀有事件的发生次数，比如：一页书上的错别字数、一小时内收到的微信数、服务器一分钟内的访问量。

定义 1.1 (公式与参数)

若随机变量 $X \sim P(\lambda)$ ，则其分布律为：

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

- 含义： k 是发生的次数。
- 参数 λ ：代表该时间段内事件发生的平均速率（强度）。如果平均每小时来 5 个人，那 $\lambda = 5$ 。

1.2 泊松分布：二项分布的极限 ★

定义 1.2 (泊松分布的物理模型)

假设我们观察一个固定的时间段 T ，该时段内事件发生的平均次数为 λ 。为了研究事件发生的具体概率，我们采用“无限分割法”：

- 将时间段 T 等分成 n 个极小的时间片，当 $n \rightarrow \infty$ 时，每个时间片 $\Delta t \rightarrow 0$ 。
- 假设 1：在极小的时间片内，事件要么发生 1 次，要么不发生（发生 2 次及以上的概率是高阶无穷小，忽略不计）。
- 假设 2：每个时间片内发生事件的概率为 p_n 。由于总平均次数为 λ ，故 $n \cdot p_n = \lambda$ ，即每次试验成功的概率 $p_n = \frac{\lambda}{n}$ 。
- 各个时间片之间是相互独立的（伯努利试验序列）。

定理 1.1 (泊松极限定理)

在上述假设下，二项分布 $B(n, \frac{\lambda}{n})$ 当 $n \rightarrow \infty$ 时的极限即为泊松分布。

证明 设 X 为 n 个时间片中事件发生的总次数，则 X 服从二项分布：

$$P(X = k) = C_n^k p^k (1-p)^{n-k}, \quad \text{其中 } p = \frac{\lambda}{n}$$

展开组合数并代入 p ：

$$P(X = k) = \frac{n(n-1)\cdots(n-k+1)}{k!} \cdot \left(\frac{\lambda}{n}\right)^k \cdot \left(1 - \frac{\lambda}{n}\right)^{n-k}$$

为了求极限，我们将式子重新分组：

$$P(X=k) = \frac{\lambda^k}{k!} \cdot \underbrace{\frac{n(n-1)\cdots(n-k+1)}{n^k}}_{\text{第一部分}} \cdot \underbrace{\left(1 - \frac{\lambda}{n}\right)^n}_{\text{第二部分}} \cdot \underbrace{\left(1 - \frac{\lambda}{n}\right)^{-k}}_{\text{第三部分}}$$

现在令 $n \rightarrow \infty$ ，我们逐项分析极限：

- 第一部分：分子有 k 项，分母是 n^k 。当 n 很大时， $(n-1) \approx n$ ，故：

$$\lim_{n \rightarrow \infty} \frac{n}{n} \cdot \frac{n-1}{n} \cdots \frac{n-k+1}{n} = 1 \cdot 1 \cdots 1 = 1$$

- 第二部分：这是重要极限的定义形式 $\lim_{x \rightarrow \infty} (1 - \frac{1}{x})^x = e^{-1}$ ，故：

$$\lim_{n \rightarrow \infty} \left(1 - \frac{\lambda}{n}\right)^n = e^{-\lambda}$$


- 第三部分：当 $n \rightarrow \infty$ 时， $\frac{\lambda}{n} \rightarrow 0$ ，故：

$$\lim_{n \rightarrow \infty} \left(1 - \frac{\lambda}{n}\right)^{-k} = (1 - 0)^{-k} = 1$$

将三部分合起来，得证：

$$\lim_{n \rightarrow \infty} P(X=k) = \frac{\lambda^k}{k!} \cdot 1 \cdot e^{-\lambda} \cdot 1 = \frac{\lambda^k e^{-\lambda}}{k!}$$

1.3 指数分布 (Exponential Distribution)

 **笔记** [核心直觉：等待时间] 指数分布和泊松分布是“孪生兄弟”。如果“单位时间内来的人数”服从泊松分布，那么“两个人到达的时间间隔”就服从指数分布。

它关心的是：你要等多久，下一件事才会发生？

定义 1.3 (公式与参数)

若 $X \sim E(\lambda)$ ，其概率密度函数 (PDF) 为：

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

- 参数 λ ：和泊松分布的 λ 含义一样，是发生速率。
- 期望： $E(X) = 1/\lambda$ 。直觉：如果你平均每小时接 5 个电话 ($\lambda = 5$)，那你平均等待 1/5 小时 (12 分钟) 就能接到下一个。




性质 [无记忆性 (Memorylessness)] 这是指数分布最牛的性质：

$$P(X > s+t \mid X > s) = P(X > t)$$

人话解释：假设你在等公交车（且公交车服从指数分布），你已经等了 10 分钟没车来。再等 5 分钟车会来的概率，和你刚到站时等 5 分钟车会来的概率是一模一样的！过去的等待通过，不会影响未来。

1.4 指数分布：泊松过程的等待时间 ★

 **笔记** [核心思想] 指数分布并不是凭空出现的。它是泊松过程的“时间视角”。如果事件发生的次数服从泊松分布，那么相邻两次事件的间隔时间必然服从指数分布。

定理 1.2 (从泊松推导指数密度)

设某事件发生的次数服从参数为 λ 的泊松过程。令随机变量 T 为等待第一次事件发生的时间。证明： T 的概率密度函数为 $f(t) = \lambda e^{-\lambda t}$ ($t > 0$)。



证明 我们使用分布函数法 (CDF Method) 进行推导。

第一步：建立等价事件 $\{T > t\}$ 表示“等待时间超过了 t ”。这等价于：在时间段 $[0, t]$ 内，事件发生的次数 $N(t)$ 为 0。

第二步：利用泊松分布计算概率时间段长为 t ，单位时间平均发生 λ 次，故该时间段内的平均发生次数为 λt 。根据泊松分布公式 $P(N = k) = \frac{\mu^k e^{-\mu}}{k!}$ ，其中 $\mu = \lambda t, k = 0$ ：

$$P(T > t) = P(N(t) = 0) = \frac{(\lambda t)^0 e^{-\lambda t}}{0!} = e^{-\lambda t}$$

第三步：求分布函数 $F(t)$

$$F(t) = P(T \leq t) = 1 - P(T > t) = 1 - e^{-\lambda t} \quad (t \geq 0)$$

(当 $t < 0$ 时，时间不可能为负，故 $F(t) = 0$)

第四步：求导得密度函数 $f(t)$ 对分布函数求导即得概率密度函数 (PDF)：

$$f(t) = F'(t) = (1 - e^{-\lambda t})' = 0 - (-\lambda)e^{-\lambda t} = \lambda e^{-\lambda t}$$

综上所述，指数分布的密度函数为：

$$f(t) = \begin{cases} \lambda e^{-\lambda t}, & t > 0 \\ 0, & t \leq 0 \end{cases}$$

1.5 正态分布 (Normal / Gaussian Distribution)



笔记 [核心直觉：误差的叠加] 为什么正态分布在自然界中无处不在？因为根据中心极限定理，如果一个量是由许多相互独立的微小因素叠加而成的，它就服从正态分布。

例子：人的身高（受基因、营养、环境等无数微小因素影响）、测量误差、热噪声。

定义 1.4 (高斯分布)

若 $X \sim N(\mu, \sigma^2)$ ，其密度函数为：

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

这个公式看着吓人，其实就是个钟形曲线：

- $(x - \mu)^2$ ：决定了关于 μ 对称。
- $e^{-\dots}$ ：决定了离中心越远，概率衰减越快。
- σ ：决定了钟形的胖瘦（波动大小）。



关于正态分布，我们后面还会介绍到关于它的更多的应用，以此来强化我们对其的直观感受，而此处只需记住其公式即可


第2章 多维随机变量：从点到面

在本章中，我们不再孤立地看某一个变量，而是研究两个（或多个）变量之间的相互关系。

内容提要

- 联合分布： X 和 Y 同时发生的概率（全貌）。 □ 条件分布：已知 $Y = y$ 发生了，此时 X 的规律
- 边缘分布：不管 Y 取啥，只看 X 的概率（投影/影子）。 □ 独立性与相关性：它们到底有什么关系？

2.1 联合、边缘与条件分布

 **笔记** [直观理解：三维蛋糕] 对于连续型二维随机变量 (X, Y) ，其概率密度函数 $f(x, y)$ 就像一个起伏不平的 **地形图** 或 **蛋糕表面**。

- 体积：曲面下方的总体积必须是 1（归一化）。
- 边缘密度 $f_X(x)$ ：把蛋糕向 x 轴压缩投影，得到的侧面轮廓。
- 条件密度 $f_{X|Y}(x|y)$ ：沿着 $Y = y$ 切一刀，剩下的那个切面的形状（归一化后）。

定义 2.1 (核心公式速查)

- 边缘密度（积分掉不需要的变量）：

$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy$$

- 条件密度（联合除以边缘）：

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)} \quad (\text{类比 } P(A|B) = \frac{P(AB)}{P(B)})$$

- 独立性判断（充要条件）：

$$f(x, y) = f_X(x) \cdot f_Y(y)$$

如果联合密度能拆成“关于 x 的函数”乘以“关于 y 的函数”，且定义域是矩形区域，则 X, Y 独立。



2.2 极值分布公式

定理 2.1 (极值分布公式推导)

设总体分布函数为 $F(x)$ ，密度为 $f(x)$ 。

1. 最大值的分布 $F_{\max}(z)$

$$P(Z_{\max} \leq z) = P(X_1 \leq z, X_2 \leq z, \dots, X_n \leq z)$$

因为独立，概率相乘：

$$F_{\max}(z) = P(X_1 \leq z) \cdots P(X_n \leq z) = [F(z)]^n$$

2. 最小值的分布 $F_{\min}(z)$ 先求 $P(Z_{\min} > z)$ （大家都大于 z ）：

$$P(Z_{\min} > z) = P(X_1 > z, \dots, X_n > z) = [1 - F(z)]^n$$

所以分布函数为：

$$F_{\min}(z) = 1 - [1 - F(z)]^n$$




第3章 变量代换：怎么求 $Y = g(X)$?

内容提要

□ 很多时候我们知道 X 的分布，但要求 $Y = X^2, Y = e^X$ 或 $Z = X + Y$ 的分布。 □ 这一章全是计算题干货，掌握“两大通法”，保你大题不丢分。

3.1 一维变换：万能的分布函数法 (CDF Method)

 **笔记** [核心心法] 不要去背那个带导数的公式 ($f_Y(y) = f_X[h(y)]|h'(y)|$)，那个公式只对单调函数有效，遇到 $Y = X^2$ 直接暴毙。

永远使用“分布函数法”三部曲：

1. 写定义： $F_Y(y) = P(Y \leq y) = P(g(X) \leq y)$ 。
2. 换元：把不等式 $g(X) \leq y$ 转化为 X 的范围（这一步最关键，要在积分区域上画图）。
3. 求导：算出 $F_Y(y)$ 后，求导得到 $f_Y(y) = F'_Y(y)$ 。

例题 3.1 经典考题：卡方分布的雏形 设 $X \sim N(0, 1)$ ，求 $Y = X^2$ 的概率密度函数。

解 1. 确定范围：因为 $X^2 \geq 0$ ，所以当 $y < 0$ 时， $f_Y(y) = 0$ 。下面只讨论 $y \geq 0$ 。

2. 写分布函数：

$$F_Y(y) = P(Y \leq y) = P(X^2 \leq y) = P(-\sqrt{y} \leq X \leq \sqrt{y})$$

3. 转化为 X 的积分（或者直接用 CDF 表示）：

$$F_Y(y) = F_X(\sqrt{y}) - F_X(-\sqrt{y})$$

4. 两边对 y 求导（注意链式法则）：

$$\begin{aligned} f_Y(y) &= f_X(\sqrt{y}) \cdot (\sqrt{y})' - f_X(-\sqrt{y}) \cdot (-\sqrt{y})' \\ f_Y(y) &= f_X(\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} - f_X(-\sqrt{y}) \cdot \left(-\frac{1}{2\sqrt{y}}\right) \\ f_Y(y) &= \frac{1}{2\sqrt{y}} [f_X(\sqrt{y}) + f_X(-\sqrt{y})] \end{aligned}$$

代入标准正态密度 $f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$ ，且注意到 f_X 是偶函数：

$$f_Y(y) = \frac{1}{2\sqrt{y}} \cdot 2 \cdot \frac{1}{\sqrt{2\pi}} e^{-(\sqrt{y})^2/2} = \frac{1}{\sqrt{2\pi y}} e^{-y/2} \quad (y > 0)$$

注：这就是自由度为 1 的 χ^2 分布。

例题 3.2 真题实战：看似复杂实则简单的线性变换 设随机变量 X 的概率密度为：

$$f(x) = C_n \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}, \quad -\infty < x < +\infty$$

其中 C_n 为正常数， n 为正整数。求随机变量 $Y = \frac{1}{\sqrt{n}}X$ 的概率密度 $f_Y(y)$ 。

解 第一步：写出 Y 的分布函数定义

$$F_Y(y) = P(Y \leq y) = P\left(\frac{1}{\sqrt{n}}X \leq y\right)$$

第二步：转化为 X 的范围因为 $\frac{1}{\sqrt{n}} > 0$ ，不等号不改变方向：

$$F_Y(y) = P(X \leq \sqrt{n}y) = F_X(\sqrt{n}y)$$

第三步：利用链式法则求导两边对 y 求导得到密度函数：


$$f_Y(y) = F'_Y(y) = f_X(\sqrt{ny}) \cdot (\sqrt{ny})' = \sqrt{n} f_X(\sqrt{ny})$$

第四步：代入并化简（关键步骤）把 $f_X(x)$ 表达式中的 x 全部替换成 \sqrt{ny} ：

$$\begin{aligned} f_Y(y) &= \sqrt{n} \cdot C_n \left(1 + \frac{(\sqrt{ny})^2}{n} \right)^{-\frac{n+1}{2}} \\ &= \sqrt{n} C_n \left(1 + \frac{ny^2}{n} \right)^{-\frac{n+1}{2}} \\ &= \sqrt{n} C_n (1 + y^2)^{-\frac{n+1}{2}} \end{aligned}$$

结论：

$$f_Y(y) = \sqrt{n} C_n (1 + y^2)^{-\frac{n+1}{2}}, \quad -\infty < y < +\infty$$

 **笔记** [观察] 如果 $n = 1$ ，这实际上就是柯西分布（Cauchy Distribution）的某种变体。这类题目不用害怕 $f(x)$ 长得复杂，只要代入进去，里面的系数往往会刚好消掉。

3.2 二维变换的本质：重积分通法

定义 3.1 (通用公式)


设 $Z = g(X, Y)$ ，求 $f_Z(z)$ 。我们不背特定公式，而是直接从定义出发：

$$F_Z(z) = P(g(X, Y) \leq z) = \iint_{D_z} f(x, y) dx dy$$

其中积分区域 $D_z = \{(x, y) \mid g(x, y) \leq z\}$ 。

算出 $F_Z(z)$ 后，求导即得 $f_Z(z)$ 。



 **笔记** [核心心法：画图是灵魂] 解决这类问题的关键不在于积分技巧，而在于能不能正确画出不等式 $g(x, y) \leq z$ 描述的区域。

3.3 三大经典模型的几何视角

3.3.1 1. 和的分布 $Z = X + Y$ （线性扫描）

- **不等式**： $x + y \leq z \implies y \leq z - x$ 。
- **几何意义**：直线 $y = -x + z$ 左下方与定义域的交集。
- **动图想象**：一条斜率为 -1 的直线从左下方向右上方扫描。

3.3.2 2. 积的分布 $Z = XY$ （双曲线扫描）

- **不等式**： $xy \leq z$ 。
- **几何意义**：
 - 若 $x > 0$ ，则 $y \leq z/x$ （双曲线下方）。
 - 若 $x < 0$ ，则 $y \geq z/x$ （双曲线上方，注意不等号变向！）。
- **难点**：积分区域往往是由双曲线和坐标轴围成的“曲边梯形”。

3.3.3 3. 商的分布 $Z = X/Y$ （旋转扫描）

- **不等式**： $X/Y \leq z$ 。

• **几何意义**：这是一束过原点的射线。

• 若 $y > 0$ ，则 $x \leq zy$ （直线左侧）。

• 若 $y < 0$ ，则 $x \geq zy$ （直线右侧）。

• **动图想象**：一条过原点的直线像雷达一样旋转扫描，扫过的角度即为概率。

例题 3.3 实战：高分布的重积分法 设 $X, Y \sim E(1)$ 独立（指数分布），求 $Z = X/Y$ 的密度。

解 1. 确定区域： $x > 0, y > 0$ （第一象限）。 $X/Y \leq z \implies x \leq zy$ 。由于 x, y 均为正，积分区域 D_z 是第一象限中直线 $x = zy$ 的上方部分（夹在 y 轴和直线之间）。

2. 建立重积分：

$$F_Z(z) = \iint_{D_z} e^{-x} e^{-y} dx dy$$

最好先积 x （从 0 积到 zy ），再积 y （从 0 到 $+\infty$ ）：

$$F_Z(z) = \int_0^{+\infty} dy \int_0^{zy} e^{-x-y} dx$$

3. 计算内层积分：

$$\int_0^{zy} e^{-x-y} dx = e^{-y}(1 - e^{-zy}) = e^{-y} - e^{-(1+z)y}$$

4. 计算外层积分：

$$F_Z(z) = \int_0^{+\infty} (e^{-y} - e^{-(1+z)y}) dy = \left[-e^{-y} + \frac{e^{-(1+z)y}}{1+z} \right]_0^{+\infty}$$

$$F_Z(z) = (0 - 0) - (-1 + \frac{1}{1+z}) = 1 - \frac{1}{1+z} = \frac{z}{1+z} \quad (z > 0)$$

5. 求导：

$$f_Z(z) = F'_Z(z) = \frac{1}{(1+z)^2}, \quad z > 0$$

注：这就是著名的 F 分布（变形）或 Log-Logistic 分布的一种。你看，完全不需要背公式！

例题 3.4 实战：均匀分布的乘积（反直觉的结果） 设 $X, Y \sim U(0, 1)$ 且相互独立。求 $Z = XY$ 的概率密度函数。

解 1. 几何建模联合密度 $f(x, y) = 1$ ，定义域为单位正方形 $D = \{(x, y) \mid 0 \leq x \leq 1, 0 \leq y \leq 1\}$ 。

我们要计算分布函数 $F_Z(z) = P(XY \leq z)$ 。

• 当 $z < 0$ 时， $F_Z(z) = 0$ ；当 $z > 1$ 时， $F_Z(z) = 1$ 。

• 关键在于 $0 < z < 1$ 时。不等式 $xy \leq z$ 对应的区域是双曲线 $y = z/x$ 的下方。

2. 积分策略：算补集（抠补法）直接算双曲线下方的面积比较麻烦（要分段积分）。我们不妨算右上方的补集区域 A^c （即 $XY > z$ 的部分），然后用 1 减去它。

补集区域 $D_{>z}$ 满足： $z < x \leq 1$ 且 $z/x < y \leq 1$ 。

$$P(XY > z) = \int_z^1 dx \int_{z/x}^1 1 \cdot dy$$

3. 执行积分先积 y ：

$$\int_{z/x}^1 dy = 1 - \frac{z}{x}$$

再积 x ：

$$\int_z^1 \left(1 - \frac{z}{x}\right) dx = [x - z \ln x]_z^1$$

代入上下限：

$$= (1 - z \ln 1) - (z - z \ln z) = 1 - z + z \ln z$$

4. 得到分布函数

$$F_Z(z) = 1 - P(XY > z) = 1 - (1 - z + z \ln z) = z - z \ln z \quad (0 < z < 1)$$

5. 求导得密度

$$f_Z(z) = F'_Z(z) = (z)' - (z \ln z)' = 1 - \left(1 \cdot \ln z + z \cdot \frac{1}{z}\right) = 1 - (\ln z + 1) = -\ln z$$

结论:

$$f_Z(z) = \begin{cases} -\ln z, & 0 < z < 1 \\ 0, & \text{其他} \end{cases}$$

第4章 条件期望：预测的艺术

内容提要

- 条件期望 $E(X|Y)$ 到底是一个数还是一个随机变量？
- 它是现代统计学和机器学习（如回归分析）的理论基石。
- 本章核心工具：重期望公式（Law of Iterated Expectation），又称“双重期望公式”。


4.1 核心概念：从“切片”到“函数”

定义 4.1 (两个层面的定义)

1. 作为数值 $E(X|Y = y)$ ：这是一个普通的实数，表示“在 Y 已经取定为 y 的条件下， X 的平均值”。

$$E(X|Y = y) = \int_{-\infty}^{+\infty} x \cdot f_{X|Y}(x|y) dx$$

2. 作为随机变量 $E(X|Y)$ ：这是一个关于 Y 的函数 $g(Y)$ 。因为 Y 是随机的，所以 $g(Y)$ 也是随机的。它代表了“在观察到 Y 之后，我们对 X 的最佳估计”。

 **笔记** [直观理解] 假设 X 是这种身高的分布， Y 是性别。

- $E(X|Y = \text{男}) = 175$ (这是一个具体的数)。
- $E(X|Y)$ 是一个随机变量，它有两个取值：如果抽到男，值就是 175；如果抽到女，值就是 163。
- 一句话总结： $E(X|Y)$ 是 Y 的函数，但在求期望的外层 $E[\cdot]$ 看来，它就是 X 的替身。

4.2 四大性质（解题外挂）

性质 [条件期望的运算规则] 设 $g(Y)$ 是关于 Y 的任意函数（即一旦 Y 确定， $g(Y)$ 就已知）。

1. 常数性： $E(c|Y) = c$ 。如果 X 已经由 Y 决定了，那期望就是它自己。
2. 线性： $E(aX_1 + bX_2|Y) = aE(X_1|Y) + bE(X_2|Y)$ 。
3. 剔除已知因子 (Taking out what is known):

$$E[g(Y) \cdot X | Y] = g(Y) \cdot E(X|Y)$$

口诀：既然在这个条件下 Y 是已知的，那 $g(Y)$ 就是个常数，可以直接提到期望外面去。

4. 重期望公式 (Tower Property / Adam's Law):

$$E[E(X|Y)] = E(X)$$

含义：“估计的估计”平均下来就是“真实的平均”。这是解决复杂期望问题的核武器。

例题 4.1 巧用条件期望：秒杀几何分布 设随机变量 $X \sim G(p)$ （表示首次成功所需的试验次数）。求 $E(X)$ 。

传统做法：计算级数 $\sum_{k=1}^{\infty} k \cdot p(1-p)^{k-1}$ ，需要错位相减法，计算量大且容易错。**条件期望做法**：利用第一次试验的结果进行分解。

解 我们根据第一次试验是否成功来使用全期望公式。记 $A = \{\text{第一次试验成功}\}$ 。

$$E(X) = E(X|A)P(A) + E(X|\bar{A})P(\bar{A})$$

分析两种情况：

1. 如果第一次成功 (A 发生)：概率为 p 。此时试验结束，总次数 $X = 1$ 。

$$E(X|A) = 1$$

2. 如果第一次失败 (\bar{A} 发生): 概率为 $1-p$ 。此时浪费了 1 次机会, 一切重头再来。由于过程的无记忆性, 之后所需的平均次数依然是 $E(X)$ 。加上刚才浪费的那 1 次, 总期望为 $1 + E(X)$ 。

$$E(X|\bar{A}) = 1 + E(X)$$

建立方程:

$$E(X) = 1 \cdot p + [1 + E(X)] \cdot (1-p)$$

求解 $E(X)$:

$$E(X) = p + 1 - p + (1-p)E(X)$$

$$E(X) = 1 + (1-p)E(X)$$

$$pE(X) = 1 \implies E(X) = \frac{1}{p}$$

注: 这就是递归法。它避免了复杂的级数求和, 直接把概率问题变成了代数方程。

4.3 协方差与相关系数：量化关系

定义 4.2 (计算核心)

- 协方差定义式:

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$$

- 协方差计算式 (做题专用):

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$$

- 相关系数:

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$$



4.4 五大核心恒等式 (运算律)

性质 [线性运算律] 协方差的运算性质非常像乘法, 满足交换律、结合律和分配律。设 a, b, c, d 为常数:

- 对称性:

$$\text{Cov}(X, Y) = \text{Cov}(Y, X)$$

- 常数“透明”性 (常数与变量无相关):

$$\text{Cov}(X, c) = 0$$

- 双线性 (系数提出的倍数关系):

$$\text{Cov}(aX, bY) = ab \text{Cov}(X, Y)$$

- 平移不变性 (加减常数不影响波动关系):

$$\text{Cov}(X + a, Y + b) = \text{Cov}(X, Y)$$

- 分配律 (最重要!):

$$\text{Cov}(X_1 + X_2, Y) = \text{Cov}(X_1, Y) + \text{Cov}(X_2, Y)$$

综合应用公式:

$$\text{Cov}(aX + b, cY + d) = ac \text{Cov}(X, Y)$$

4.5 方差的展开公式 (必考)

定理 4.1 (和差方差公式)

这就像代数中的完全平方公式 $(a+b)^2 = a^2 + b^2 + 2ab$ 。

$$D(X \pm Y) = D(X) + D(Y) \pm 2Cov(X, Y)$$

特别注意:

- 只有当 X, Y 不相关 ($Cov = 0$) 时, 才有 $D(X \pm Y) = D(X) + D(Y)$ 。
- 如果 X, Y 独立, 则一定不相关, 公式成立。



笔记 [推广: 项数更多的展开]

$$D\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n D(X_i) + 2 \sum_{1 \leq i < j \leq n} Cov(X_i, X_j)$$

如果是独立同分布 (i.i.d) 的变量求和, 后面那一堆 Cov 全是 0, 于是 $D(\sum X_i) = nD(X)$ 。

4.6 “不相关”与“独立”

表 4.1: 独立 vs 不相关

关系	结论
独立 \Rightarrow 不相关	成立 。独立意味着完全没关系, 自然没有线性关系。
不相关 \Rightarrow 独立	不一定 。 $Cov = 0$ 只排除了线性关系, 可能存在 $Y = X^2$ 这种非线性关系。
二维正态分布情形	等价 。对于 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, $\rho = 0 \Leftrightarrow$ 独立。

例题 4.2 经典反例: 不相关但不独立 设 $X \sim U(-1, 1)$, 令 $Y = X^2$ 。显然 X, Y 不独立 (Y 完全由 X 决定)。但计算协方差:

- $E(X) = 0$
- $E(XY) = E(X \cdot X^2) = E(X^3) = \int_{-1}^1 \frac{1}{2} x^3 dx = 0$ (奇函数积分)
- $Cov(X, Y) = E(XY) - E(X)E(Y) = 0 - 0 = 0$

结论: X 和 X^2 不相关, 但它们紧密相连。

第5章 三大核心分布的期望与方差推导


内容提要

□ 本章属于“内功心法”。

积分和级数的基本功。

□ 掌握这些推导，你不仅记住了公式，更复习了微 □ 核心技巧：级数下标变换、分部积分、换元积分。

5.1 泊松分布 $X \sim P(\lambda)$

 **笔记** [推导策略] 离散型求期望，核心难点在于消去分母的 $k!$ 。技巧：利用 $k/k! = 1/(k-1)!$ 进行“降阶”，然后凑出 e^λ 的泰勒展开式。对于方差，尽量算 $E[X(X-1)]$ 而不是直接算 $E(X^2)$ 。

证明 [1. 期望 $E(X)$ 的推导]

$$E(X) = \sum_{k=0}^{\infty} k \cdot P(X=k) = \sum_{k=0}^{\infty} k \cdot \frac{\lambda^k e^{-\lambda}}{k!}$$

当 $k=0$ 时第一项为 0，故求和从 $k=1$ 开始。消去 k ：

$$E(X) = e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^k}{(k-1)!}$$

令 $j = k-1$ (下标平移)，则 $\lambda^k = \lambda \cdot \lambda^j$ ：

$$E(X) = \lambda e^{-\lambda} \underbrace{\sum_{j=0}^{\infty} \frac{\lambda^j}{j!}}_{\text{此即 } e^\lambda} = \lambda e^{-\lambda} \cdot e^\lambda = \lambda$$

证明 [2. 方差 $D(X)$ 的推导] 利用公式 $D(X) = E(X^2) - [E(X)]^2$ 。我们先求二阶矩 $E(X^2)$ 。直接求 $\sum k^2 \frac{\lambda^k}{k!}$ 较难，不如利用 ** 二阶阶乘矩 **：

$$X^2 = X(X-1) + X \implies E(X^2) = E[X(X-1)] + E(X)$$

计算 $E[X(X-1)]$ ：

$$E[X(X-1)] = \sum_{k=0}^{\infty} k(k-1) \frac{\lambda^k e^{-\lambda}}{k!}$$

$k=0, 1$ 时项为 0，求和从 $k=2$ 开始。消去 $k(k-1)$ ：

$$= e^{-\lambda} \sum_{k=2}^{\infty} \frac{\lambda^k}{(k-2)!}$$


令 $j = k-2$ ，则 $\lambda^k = \lambda^2 \cdot \lambda^j$ ：

$$= \lambda^2 e^{-\lambda} \sum_{j=0}^{\infty} \frac{\lambda^j}{j!} = \lambda^2 e^{-\lambda} \cdot e^\lambda = \lambda^2$$

代回方差公式：

$$D(X) = E(X^2) - [E(X)]^2 = (\lambda^2 + \lambda) - \lambda^2 = \lambda$$

5.2 指数分布 $X \sim E(\lambda)$

 **笔记** [推导策略] 连续型求期望，核心是分部积分法 (**Integration By Parts**)。记住公式： $\int u dv = uv - \int v du$ 。这里需要反复对 $xe^{-\lambda x}$ 这种形式进行积分。

证明 [1. 期望 $E(X)$ 的推导]

$$E(X) = \int_{-\infty}^{+\infty} xf(x)dx = \int_0^{+\infty} x \cdot \lambda e^{-\lambda x} dx$$

令 $u = x, dv = \lambda e^{-\lambda x} dx$, 则 $du = dx, v = -e^{-\lambda x}$ 。

$$E(X) = [-xe^{-\lambda x}]_0^{+\infty} - \int_0^{+\infty} (-e^{-\lambda x})dx$$

第一项：利用洛必达法则可知 $\lim_{x \rightarrow \infty} xe^{-\lambda x} = 0$, 故第一项为 $0 - 0 = 0$ 。

$$E(X) = \int_0^{+\infty} e^{-\lambda x} dx = \left[-\frac{1}{\lambda} e^{-\lambda x}\right]_0^{+\infty} = 0 - \left(-\frac{1}{\lambda}\right) = \frac{1}{\lambda}$$

证明 [2. 方差 $D(X)$ 的推导] 先求 $E(X^2)$:

$$E(X^2) = \int_0^{+\infty} x^2 \cdot \lambda e^{-\lambda x} dx$$

分部积分：令 $u = x^2, dv = \lambda e^{-\lambda x} dx$, 则 $du = 2xdx, v = -e^{-\lambda x}$ 。

$$E(X^2) = \underbrace{[-x^2 e^{-\lambda x}]_0^{+\infty}}_0 + \int_0^{+\infty} 2xe^{-\lambda x} dx$$


提取常数 2 和 $1/\lambda$ (构造期望的形式):

$$= \frac{2}{\lambda} \int_0^{+\infty} x \cdot \lambda e^{-\lambda x} dx = \frac{2}{\lambda} \cdot E(X) = \frac{2}{\lambda} \cdot \frac{1}{\lambda} = \frac{2}{\lambda^2}$$

计算方差:

$$D(X) = E(X^2) - [E(X)]^2 = \frac{2}{\lambda^2} - \left(\frac{1}{\lambda}\right)^2 = \frac{1}{\lambda^2}$$

5.3 正态分布 $X \sim N(\mu, \sigma^2)$

 **笔记 [推导策略]** 核心技巧是换元法 (令 $t = \frac{x-\mu}{\sigma}$) 和利用奇偶性。不要硬算 e^{-x^2} 的原函数 (算不出来的), 要利用 $\int_{-\infty}^{+\infty} t\phi(t)dt = 0$ 这种性质。

证明 [1. 期望 $E(X)$ 的推导]

$$E(X) = \int_{-\infty}^{+\infty} x \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx$$

令 $t = \frac{x-\mu}{\sigma}$, 则 $x = \sigma t + \mu, dx = \sigma dt$ 。

$$E(X) = \int_{-\infty}^{+\infty} (\sigma t + \mu) \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$

拆分为两项:

$$= \underbrace{\sigma \int_{-\infty}^{+\infty} t \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt}_{I_1} + \underbrace{\mu \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt}_{I_2}$$

- 对于 I_1 : 被积函数是奇函数, 且积分区间对称, 故积分为 0。
- 对于 I_2 : 被积函数是标准正态分布 $N(0,1)$ 的密度, 全积分必为 1。

$$\therefore E(X) = \sigma \cdot 0 + \mu \cdot 1 = \mu$$

证明 [2. 方差 $D(X)$ 的推导] 利用定义 $D(X) = E[(X - \mu)^2]$ 计算更简便。

$$D(X) = \int_{-\infty}^{+\infty} (x - \mu)^2 \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx$$

同样令 $t = \frac{x-\mu}{\sigma}$, 则 $(x-\mu)^2 = \sigma^2 t^2$:

$$D(X) = \int_{-\infty}^{+\infty} \sigma^2 t^2 \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt = \frac{\sigma^2}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} t^2 e^{-\frac{t^2}{2}} dt$$

对积分部分 $\int_{-\infty}^{+\infty} t^2 e^{-t^2/2} dt$ 使用分部积分: 拆分 $t^2 e^{-t^2/2} = t \cdot (te^{-t^2/2})$ 。令 $u = t, dv = te^{-t^2/2} dt$, 则 $du = dt, v = -e^{-t^2/2}$ 。

$$\begin{aligned} \int_{-\infty}^{+\infty} t^2 e^{-t^2/2} dt &= \underbrace{\left[-te^{-t^2/2} \right]_{-\infty}^{+\infty}}_0 - \int_{-\infty}^{+\infty} -e^{-t^2/2} dt \\ &= \int_{-\infty}^{+\infty} e^{-t^2/2} dt = \sqrt{2\pi} \quad (\text{高斯积分}) \end{aligned}$$

代回原式:

$$D(X) = \frac{\sigma^2}{\sqrt{2\pi}} \cdot \sqrt{2\pi} = \sigma^2$$

第6章 极限定理的基石：两大不等式

内容提要

- 极限定理（大数定律、CLT）是概率论的皇冠。 不等式（控制尾部）和 Chebyshev 不等式（控制波动）。
- 要摘取皇冠，必须先掌握两个核心工具：Markov

6.1 Markov 不等式：非负变量的边界

定理 6.1 (Markov Inequality)

设 X 为非负随机变量（即 $P(X \geq 0) = 1$ ），且期望 $E(X)$ 存在。则对于任意常数 $a > 0$ ：

$$P(X \geq a) \leq \frac{E(X)}{a}$$



笔记 [直观理解]

- 这是一个很宽松的上界，但它非常通用（只要求期望存在，且非负）。
- 含义：一个平均值很小的变量，取极大值的概率不可能很大。
- 比如：全班平均分 60 分（且不能为负分），那么 120 分以上的人数比例最多是 $60/120 = 1/2$ ？（哦不对，分数不能超 100，但逻辑是这个逻辑：平均值限制了极端值的比例）。

证明 [利用示性函数证明] 定义示性函数 $I_{\{X \geq a\}}$ ：当 $X \geq a$ 时取 1，否则取 0。由于 $X \geq 0$ ，显见以下不等式恒成立：

$$a \cdot I_{\{X \geq a\}} \leq X$$

（当 $X < a$ 时，左边为 0，右边 ≥ 0 ；当 $X \geq a$ 时，左边为 a ，右边 $\geq a$ 。）

两边同时求期望：

$$E[a \cdot I_{\{X \geq a\}}] \leq E(X)$$

$$a \cdot E[I_{\{X \geq a\}}] \leq E(X)$$

因为示性函数的期望即为概率 $P(X \geq a)$ ：

$$a \cdot P(X \geq a) \leq E(X) \implies P(X \geq a) \leq \frac{E(X)}{a}$$

6.2 Chebyshev 不等式：波动的控制

笔记 [核心思想] Markov 不等式只用了“期望”信息。如果我们还知道“方差”，能得到更精确的界吗？Chebyshev 不等式本质上就是把 Markov 不等式应用在 $(X - \mu)^2$ 上。

定理 6.2 (Chebyshev Inequality)

设随机变量 X 的期望为 μ ，方差为 σ^2 。则对于任意 $\varepsilon > 0$ ：

$$P(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}$$

或者写成 3σ 准则的形式（令 $\varepsilon = k\sigma$ ）：

$$P(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}$$



证明 [一句话推导] 我们要估计 $P(|X - \mu| \geq \varepsilon)$ 。这等价于估计 $P((X - \mu)^2 \geq \varepsilon^2)$ 。

令 $Y = (X - \mu)^2$ 。显见 Y 是非负随机变量，且 $E(Y) = D(X) = \sigma^2$ 。直接对 Y 使用 Markov 不等式（取 $a = \varepsilon^2$ ）：

$$P(Y \geq \varepsilon^2) \leq \frac{E(Y)}{\varepsilon^2}$$

代回即得：

$$P(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}$$

注[Chebyshev 的威力]

- 它不依赖于分布的具体形式！不管你是正态、均匀还是什么奇形怪状的分布，只要方差存在，这个不等式就成立。
- **例：**取 $k = 3$ ，则 $P(|X - \mu| \geq 3\sigma) \leq 1/9 \approx 11\%$ 。
- 虽然正态分布中 3σ 外的概率只有 0.3%，Chebyshev 给出的 11% 显得很粗糙，但它是**万能**的。

第7章 极限定理：从混沌到秩序

内容提要

- 为什么我们可以用“频率”来估计“概率”？(大数定律)
- 为什么自然界中正态分布无处不在？(中心极限定理)
- 本章是概率论（理论）向数理统计（应用）跨越的桥梁。

7.1 大数定律 (LLN): 稳定性的保证

笔记 [直观含义] 大数定律说的是：“样本均值” \bar{X} 会依概率收敛于“总体均值” μ 。

只要样本量 n 足够大，偶然的波动会被互相抵消，最终显现出必然的规律。这是蒙特卡洛模拟 (Monte Carlo) 和所有统计估算的基石。

定理 7.1 (切比雪夫弱大数定律)

设 X_1, X_2, \dots 是独立同分布 (i.i.d) 的随机变量序列，期望 $E(X_i) = \mu$ ，方差 $D(X_i) = \sigma^2 < \infty$ 。则对于任意 $\varepsilon > 0$:

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \mu\right| < \varepsilon\right) = 1$$

即样本均值 \bar{X} 依概率收敛于 μ ，记为 $\bar{X} \xrightarrow{P} \mu$ 。

证明 [切比雪夫一秒证法 (必背)] 令样本均值 $\bar{X} = \frac{1}{n} \sum X_i$ 。

- 期望: $E(\bar{X}) = \frac{1}{n} \cdot n\mu = \mu$ 。
- 方差: $D(\bar{X}) = D(\frac{1}{n} \sum X_i) = \frac{1}{n^2} \sum D(X_i) = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n}$ 。

直接对 \bar{X} 使用切比雪夫不等式:

$$P(|\bar{X} - \mu| \geq \varepsilon) \leq \frac{D(\bar{X})}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2}$$

当 $n \rightarrow \infty$ 时，右边 $\rightarrow 0$ 。证毕。

注 [辛钦大数定律 (Khinchine's Law)] 切比雪夫大数定律要求“方差存在”。其实只要 X 独立同分布且 ** 期望存在 **，大数定律就成立。这就是辛钦大数定律 (证明需要特征函数，此处略)。

例题 7.1 伯努利大数定律 这是我们在初中就学过的：抛硬币次数越多，正面朝上的频率 $f_n = n_A/n$ 越接近概率 p 。

$$\lim_{n \rightarrow \infty} P(|f_n - p| < \varepsilon) = 1$$

7.2 中心极限定理 (CLT): 万物归宗

笔记 [核心思想] 大数定律告诉我们 \bar{X} 会收敛到一个常数 μ 。中心极限定理告诉我们：在 \bar{X} 收敛到 μ 的过程中，它的误差分布长什么样？

结论：无论 X_i 原来服从什么分布 (只要独立同分布且方差有限)，它们的和 (或均值) 在标准化后，都逼近标准正态分布。

定理 7.2 (林德伯格-列维 (Lindeberg-Lévy) 定理)

设 X_1, X_2, \dots 独立同分布，期望 μ ，方差 σ^2 。令 $Y_n = \sum_{i=1}^n X_i$ 。当 n 充分大时：

$$Z_n = \frac{Y_n - E(Y_n)}{\sqrt{D(Y_n)}} = \frac{\sum X_i - n\mu}{\sqrt{n}\sigma} = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0, 1)$$



注[解题通法] 考试中遇到“求 100 个部件总寿命大于 1000 小时的概率”或者“求 50 次实验平均误差小于 0.1 的概率”，一律按 CLT 处理：

1. 算出总和的期望 $E(\sum) = n\mu$ 。
2. 算出总和的方差 $D(\sum) = n\sigma^2$ 。
3. 标准化： $P(\sum X_i > a) \approx 1 - \Phi\left(\frac{a - n\mu}{\sqrt{n}\sigma}\right)$ 。

7.3 CLT 的终极魅力：从布朗运动到高斯白噪声

内容提要

- 为什么我们在信号处理、金融模型（如 Black-Scholes）中，总是假设噪声或收益率服从正态分布？
- 难道上帝真的只掷高斯骰子吗？
- 答案就在中心极限定理中：正态分布是大量微小随机扰动叠加的必然归宿。

例题 7.2 物理直觉：布朗运动的微观起源 考虑一个悬浮在液体中的花粉粒子。它为什么会做无规则的布朗运动？

1. 微观视角：无数次的“推搡” 在极短的时间 Δt 内，花粉粒子受到了来自四面八方的水分子的成千上万次撞击。

- 设第 i 次撞击带来的微小位移为 X_i 。
- 所有的 X_i 都是独立同分布的（水分子运动是混乱且独立的）。
- X_i 的分布可能很复杂（取决于分子速度、角度等），但这不重要！

2. 宏观累加：CLT 的介入 粒子在 Δt 时间内的总位移 ΔW 是所有微小撞击的总和：

$$\Delta W = \sum_{i=1}^N X_i$$

由于 N （撞击次数）极大（数量级可能是 10^{20} ），根据**中心极限定理 (CLT)**：无论单个分子的撞击 X_i 服从什么分布，它们的总和 ΔW **必然收敛于正态分布**。

3. 数学结论 这解释了为什么布朗运动的增量服从正态分布：

$$W(t + \Delta t) - W(t) \sim N(0, \sigma^2 \Delta t)$$

笔记 [深度：为什么“对时间的微分”是高斯分布？] 你可能会问：“位移是正态的，那速度（微分）呢？”

数学上，标准的布朗运动路径 $W(t)$ 处处连续但处处不可微（分形性质）。但在工程和物理上，我们引入广义函数的概念。

考虑“平均速度”：

$$\frac{W(t + \Delta t) - W(t)}{\Delta t} \sim \frac{N(0, \Delta t)}{\Delta t} = N\left(0, \frac{1}{\Delta t}\right)$$

当 $\Delta t \rightarrow 0$ 时，我们称其极限为高斯白噪声 (**Gaussian White Noise**)，记为 $\xi(t) = \frac{dW}{dt}$ 。


魅力所在：正是因为底层无数次撞击满足 CLT，导致了宏观上的“位移增量”是正态的，进而导致了其形式上的“导数”（白噪声）也是高斯的。这就是为什么我们在做卡尔曼滤波、信号分析时，默认噪声是高斯分布的物理依据。

第8章 参数估计：侦探的游戏

内容提要

- 之前我们学的是概率论：已知参数（如 p, λ ），预反推参数。
- 测数据。
- 现在我们进入数理统计：已知数据（手里的样本），理派）。
- 两大流派：矩估计（模仿派）与极大似然估计（推理派）。

8.1 矩估计 (MoM): 简单粗暴的模仿

 **笔记** [核心思想] “样本就是总体的缩影。”矩估计的逻辑非常直白：既然我不知道总体的均值 $E(X)$ 是多少，那我就用样本的均值 \bar{X} 去代替它。

口诀：用样本矩替换总体矩。

定义 8.1 (操作步骤)

设总体有 k 个待估参数 $\theta_1, \dots, \theta_k$ 。

- 算总体矩：计算前 k 阶原点矩 $\mu_1 = E(X), \mu_2 = E(X^2), \dots$ （这些是含 θ 的式子）。
- 算样本矩：计算样本的原点矩 $A_1 = \bar{X}, A_2 = \frac{1}{n} \sum X_i^2$ （这些是具体的数）。
- 令其相等：建立方程组

$$\begin{cases} E(X) = \bar{X} \\ E(X^2) = \frac{1}{n} \sum X_i^2 \end{cases}$$

- 反解参数：解出 $\hat{\theta}$ 即为估计量。

例题 8.1 实战：均匀分布 $U(a, b)$ 设 $X \sim U(a, b)$ ，求 a, b 的矩估计量。

解：两个未知数，需要建立两个方程。


- 总体均值 $E(X) = \frac{a+b}{2}$ ，总体二阶矩 $E(X^2) = D(X) + [E(X)]^2 = \frac{(b-a)^2}{12} + (\frac{a+b}{2})^2$ 。
- 令 $E(X) = \bar{X}$ 和 $D(X) = S_n^2$ （利用方差公式简化计算， σ^2 对应样本方差）。

$$\begin{cases} \frac{a+b}{2} = \bar{X} \\ \frac{(b-a)^2}{12} = S_n^2 \end{cases}$$

- 解得：

$$\hat{a} = \bar{X} - \sqrt{3}S_n, \quad \hat{b} = \bar{X} + \sqrt{3}S_n$$

8.2 极大似然估计 (MLE): 谁的嫌疑最大?

 **笔记** [核心思想] “存在即合理。”事情已经发生了（样本观测值 x_1, \dots, x_n 已经出现了），那么参数 θ 应该是多少，才能让“这件事发生的概率”最大？

我们把概率函数 $P(x|\theta)$ 反过来看，看作是关于 θ 的函数 $L(\theta|x)$ ，求它的最大值点。

定理 8.1 (似然函数 Likelihood Function)

- 离散型： $L(\theta) = \prod_{i=1}^n P(X_i = x_i; \theta)$
- 连续型： $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$

笔记 [MLE 标准三部曲]

1. 写似然函数： $L(\theta) = \prod f(x_i)$ 。
2. 取对数（关键）： $\ln L(\theta) = \sum \ln f(x_i)$ 。（为什么要取对数？因为连乘求导太难，变成连加求导就简单了。且 \ln 单调递增，不改变极值点位置。）
3. 求导置零：计算 $\frac{d}{d\theta} \ln L(\theta) = 0$ ，解出的 $\hat{\theta}$ 即为 MLE。

8.3 高危考点：均匀分布的 MLE

笔记 [陷阱] 如果概率密度函数的定义域包含参数 θ （例如 $U(0, \theta)$ ），绝对不能用求导法！因为此时 $L(\theta)$ 在边界处不可导，或者最大值在边界上。

例题 8.2 经典反例 设总体 $X \sim U(0, \theta)$ ，求 θ 的极大似然估计。

$$f(x) = \begin{cases} \frac{1}{\theta}, & 0 \leq x \leq \theta \\ 0, & \text{其他} \end{cases}$$

解 1. 写似然函数

$$L(\theta) = \prod_{i=1}^n f(x_i) = \begin{cases} \frac{1}{\theta^n}, & \text{当所有 } 0 \leq x_i \leq \theta \text{ 时} \\ 0, & \text{只要有一个 } x_i > \theta \end{cases}$$

2. 关键逻辑要使 $L(\theta) \neq 0$ ，必须满足所有观测值都落在 $[0, \theta]$ 内，即 $\max(x_1, \dots, x_n) \leq \theta$ 。也就是 θ 必须大于等于所有的样本值，即 $\theta \geq x_{(n)}$ 。

3. 寻找最大值在区间 $[\max(x_i), +\infty)$ 上，函数 $L(\theta) = \frac{1}{\theta^n}$ 是单调递减的。所以， θ 取最小值的时候， $L(\theta)$ 最大。

结论： $\hat{\theta}_{MLE} = \max(X_1, \dots, X_n) = X_{(n)}$ 。

对比：此题若用矩估计， $\bar{X} = \theta/2 \implies \hat{\theta}_{MoM} = 2\bar{X}$ 。显然 $X_{(n)}$ 比 $2\bar{X}$ 更合理（因为它保证了估计值一定大于所有样本）。

8.4 MLE 的巅峰应用：线性回归

内容提要

- 以前学线性回归，老师说“我们要让误差平方和最小”，这叫最小二乘法 (Least Squares)。
- 偏是“平方和”？而不是绝对值之和？
- 今天我们用 MLE 的视角重新审视它：为什么偏项。
- 结论：因为高斯分布的指数部分，刚好就是平方项。

例题 8.3 MLE 推导线性回归 设线性模型为 $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$ ($i = 1, \dots, n$)。其中误差项 ϵ_i 独立同分布，服从正态分布 $\epsilon_i \sim N(0, \sigma^2)$ 。试利用极大似然估计法估计参数 β_0, β_1 。

笔记 [看图说话] 请注意图中的蓝色高斯曲线。它垂直于 x 轴，意味着给定 x_0 后， y 的取值是一个概率分布。MLE 的本质，就是调整红色曲线的位置，使得所有蓝色数据点出现的联合概率（似然值）最大化。

解 1. 确定 y_i 的分布由于 y_i 是常数 $\beta_0 + \beta_1 x_i$ 加上随机变量 ϵ_i ，故 y_i 也服从正态分布：

$$y_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$$

其概率密度函数为：

$$f(y_i) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{[y_i - (\beta_0 + \beta_1 x_i)]^2}{2\sigma^2} \right\}$$




图 8.1: 线性回归的概率视角：数据点围绕回归线做正态波动

2. 写似然函数

$$L(\beta_0, \beta_1, \sigma^2) = \prod_{i=1}^n f(y_i) = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2 \right\}$$

3. 取对数似然

$$\ln L = \ln \left[(2\pi\sigma^2)^{-n/2} \right] - \frac{1}{2\sigma^2} \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2$$


$$\ln L = -\frac{n}{2} \ln(2\pi) - n \ln \sigma - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

4. 极大化求解 (见证奇迹的时刻) 我们要寻找 β_0, β_1 使得 $\ln L$ 最大。注意上式中，前两项与 β 无关。第三项前面有个负号。

$$\max_{\beta} (\ln L) \iff \max_{\beta} \left(-\frac{1}{2\sigma^2} \sum (y_i - \hat{y}_i)^2 \right) \iff \min_{\beta} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

结论：要让“似然概率最大” (MLE)，就必须让“残差平方和最小” (Least Squares)。这就解释了为什么最小二乘法是线性回归的最佳估计——隐含前提是误差服从正态分布。

8.5 深度思考：为什么偏偏是“平方”？

 **笔记** [灵魂拷问] 我们在做回归时，习惯性地计算残差平方和 $\sum (y_i - \hat{y}_i)^2$ 。但你有没有想过：** 为什么不是绝对值之和 $\sum |y_i - \hat{y}_i|$ ？或者 4 次方之和？**

答案：这完全取决于我们对噪声分布的假设。

定理 8.2 (损失函数与噪声分布的对应关系)

利用极大似然估计 (MLE) 的视角，不同的噪声假设对应着不同的损失函数 (Loss Function)：

1. 高斯噪声 \rightarrow 均方误差 (MSE, L2 Loss)

$$\epsilon \sim N(0, \sigma^2) \implies f(\epsilon) \propto e^{-\epsilon^2}$$

取对数后， $-\ln L \propto \sum \epsilon^2 = \sum (y_i - \hat{y}_i)^2$ 。特点：对异常值敏感（平方放大了大误差），计算方便（处处可导）。

2. 拉普拉斯噪声 \rightarrow 平均绝对误差 (MAE, L1 Loss) 假设噪声服从拉普拉斯分布 (Laplace Distribution)：

$$f(\epsilon) = \frac{1}{2b} \exp\left(-\frac{|\epsilon|}{b}\right)$$

取对数后，指数上的绝对值符号落了下来：

$$-\ln L \propto \sum |\epsilon| = \sum |y_i - \hat{y}_i|$$

特点：对异常值鲁棒 (Robust)，但在 0 点不可导。这就是为什么在处理含有很多离群点的数据时，我们要用最小绝对偏差回归 (LAD)。



注[一句话总结] 你选择什么样的方法（最小二乘还是最小绝对值），本质上是因为你相信数据背后的噪声服从什么样的分布。


- 相信正态分布 \implies 用平方 (L_2)。
- 相信拉普拉斯分布 \implies 用绝对值 (L_1)。

第9章 区间估计的前奏：三大抽样分布与枢轴量

内容提要

- 在统计学中，正态分布 $N(0,1)$ 是“上帝”。
- 但上帝有三个“亲儿子”： χ^2 分布、 t 分布、 F 分布。
- 本章将揭示它们的身世，并利用它们构造枢轴量，为区间估计打下地基。

9.1 正态分布的“拼积木”游戏

 **笔记** [核心逻辑] 所有的抽样分布，本质上都是标准正态变量 $Z \sim N(0,1)$ 的平方或商。

9.1.1 1. 卡方分布 $\chi^2(n)$ ：平方和

定义 9.1

设 X_1, \dots, X_n 独立且都服从标准正态分布 $N(0,1)$ 。则它们的平方和服从自由度为 n 的 χ^2 分布：

$$\chi^2 = \sum_{i=1}^n X_i^2 \sim \chi^2(n)$$



- 物理意义**：它衡量了 n 个标准正态误差的**总能量**（方差来源）。
- 应用**：专门用来估计**方差** σ^2 。
- 性质**： $E(\chi^2) = n, D(\chi^2) = 2n$ （具有可加性）。

9.1.2 2. t 分布 $t(n)$ ：修正的商

定义 9.2

设 $X \sim N(0,1)$ ， $Y \sim \chi^2(n)$ ，且 X, Y 独立。则下面的比值服从自由度为 n 的 t 分布：

$$T = \frac{X}{\sqrt{Y/n}} \sim t(n)$$



- 直观理解**：本来 $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$ 是标准正态。但如果我们**不知道** σ ，只能用样本标准差 S 去代替 σ 。因为 S 自己也是随机波动的（不靠谱），所以引入了额外的误差，导致分布的尾巴变“厚”了（Fat Tail）。
- 极限**：当 $n \rightarrow \infty$ 时， $S \rightarrow \sigma$ ， $t(n)$ 分布收敛于 $N(0,1)$ 。

9.1.3 3. F 分布 $F(n_1, n_2)$ ：方差之比

定义 9.3

设 $U \sim \chi^2(n_1)$ ， $V \sim \chi^2(n_2)$ ，且 U, V 独立。则它们的平均值之比服从 F 分布：

$$F = \frac{U/n_1}{V/n_2} \sim F(n_1, n_2)$$



- 应用**：专门用来比较两个正态总体的**方差**是否相等（ANOVA 的基础）。
- 性质**： $1/F \sim F(n_2, n_1)$ （倒数性质）。

9.2 通法：如何构造枢轴量？

内容提要

- 目标：我们要估计参数 θ 。与 θ 无关（是一个已知的标准分布）。
 □ 枢轴量 $G(X, \theta)$ ：这是一个混合了样本 X 和参数 θ 的函数，但它最神奇的地方在于——它的分布（ θ ）不同，但尺子本身的刻度（分布）是不变的。

表 9.1: 正态总体下的四大枢轴量（背诵版）

待估参数	已知条件	枢轴量构造	服从分布	用途
均值 μ	σ^2 已知	$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$	$N(0, 1)$	最简单的区间
	σ^2 未知	$\frac{\bar{X} - \mu}{S/\sqrt{n}}$	$t(n-1)$	必考 ：用 S 替 σ
方差 σ^2	μ 未知	$\frac{(n-1)S^2}{\sigma^2}$	$\chi^2(n-1)$	估计波动大小
	$(\mu \text{ 已知})$	$\sum \frac{(X_i - \mu)^2}{\sigma^2}$	$\chi^2(n)$	(考得少)
方差比 σ_1^2/σ_2^2	μ 未知	$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2}$	$F(n_1-1, n_2-1)$	比较精度

笔记 [易错点：自由度]

- 凡是用到样本方差 S^2 的地方，自由度通常都要减 1（变为 $n-1$ ）。
- 原因是计算 S^2 时用到了 \bar{X} ，消耗了一个自由度（ $\sum (X_i - \bar{X}) = 0$ 这一约束）。

9.3 区间估计的三步走

笔记 [解题通法]

1. 选尺子：根据已知条件（是否知道 σ ），从上表中选择合适的枢轴量。
2. 查分位点：根据置信水平 $1-\alpha$ ，查表找到分布的临界值（如 $z_{\alpha/2}, t_{\alpha/2}(n-1)$ ）。
3. 反解不等式：

$$P(-c < \text{枢轴量} < c) = 1 - \alpha$$


从中反解出 μ 或 σ^2 的范围。

9.4 进阶：双剑合璧——两个正态总体的推断

内容提要

- 现实中我们更常比较两组数据：实验组 vs 对照组、男 vs 女、旧工艺 vs 新工艺。
 □ 核心问题：两组数据的波动（精度）一样吗？
 □ 核心问题：两组数据的平均值有差异吗？（ $\mu_1 - \mu_2$ ）
 □ 核心问题：两组数据的波动（精度）一样吗？（ σ_1^2/σ_2^2 ）

9.4.1 0. 基础情形：方差 σ_1^2, σ_2^2 已知

 **笔记** [判别标准] 只要题目里明确给出了总体的标准差 σ_1, σ_2 (而不是样本标准差 s_1, s_2)，不管样本量 n 是大是小，**一律用 Z 分布**。

这是最简单、最精确的情况，不需要用 t 分布去模拟，也不需要把方差合起来算。

定理 9.1 (枢轴量)

由于 $\bar{X} \sim N(\mu_1, \sigma_1^2/n_1)$ 且 $\bar{Y} \sim N(\mu_2, \sigma_2^2/n_2)$ ，且两者独立。根据正态分布的可加性， $\bar{X} - \bar{Y}$ 依然服从正态分布。


枢轴量为标准正态分布：

$$Z = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1)$$



例题 9.1 置信区间公式 $\mu_1 - \mu_2$ 的 $1 - \alpha$ 置信区间为：

$$\left[(\bar{x} - \bar{y}) - z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, (\bar{x} - \bar{y}) + z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right]$$

 **笔记** [大样本近似] 如果 σ_1, σ_2 未知，但样本量非常大 ($n_1, n_2 > 30$)，根据大数定律， $s \approx \sigma$ 。此时也可以套用这个公式 (用 s 替换 σ)，并查 Z 表而不是 t 表。

9.4.2 1. 均值之差 $\mu_1 - \mu_2$ 的推断

 **笔记** [前提条件] 这里只讨论考试最常见的情形：

1. 两样本相互独立。
2. 均值 μ_1, μ_2 未知。
3. 方差 σ_1^2, σ_2^2 未知，但假设相等 ($\sigma_1^2 = \sigma_2^2 = \sigma^2$)。

注：如果方差不等 (Behrens-Fisher 问题)，那是研究生课程的内容，本科大概率不考。

定义 9.4 (合并方差 Pooled Variance)

既然假设方差相等，那不如把两组样本合起来，利用所有的自由度来估计这个共同的方差 σ^2 。

$$S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

理解：这是 S_1^2 和 S_2^2 的加权平均，权重是各自的自由度。

**定理 9.2 (枢轴量)**


$$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$$



例题 9.2 置信区间公式 $\mu_1 - \mu_2$ 的 $1 - \alpha$ 置信区间为：

$$(\bar{x} - \bar{y}) \pm t_{\alpha/2}(n_1 + n_2 - 2) \cdot S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$$

9.4.3 2. 方差之比 σ_1^2/σ_2^2 的推断

 **笔记** [应用场景] 比较两台机器的精度。如果置信区间包含 1，说明两台机器精度相当。

定理 9.3 (枢轴量与区间)

枢轴量： $F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$ 。

置信区间（注意左右不对称，且要交叉相除）：

$$\left[\frac{S_1^2}{S_2^2} \cdot \frac{1}{F_{\alpha/2}(n_1 - 1, n_2 - 1)}, \frac{S_1^2}{S_2^2} \cdot \frac{1}{F_{1-\alpha/2}(n_1 - 1, n_2 - 1)} \right]$$

技巧：查表时， $F_{1-\alpha/2}(n_1, n_2) = 1/F_{\alpha/2}(n_2, n_1)$ 。

**9.4.4 3. 陷阱：成对数据 (Paired Data)**

笔记 [千万别用错公式] 如果题目说是“同一组人减肥前后的体重”或者“同一块地施肥左右两边的产量”，这是成对数据！

- 它们不独立（同一个人的体重肯定相关）。
- 解法：做差 $D_i = X_i - Y_i$ 。
- 然后把 D_i 看作一个新的单样本，对 D 的均值 μ_D 做 t 检验。
- 此时自由度是 $n - 1$ (n 为对数)，而不是 $2n - 2$ 。

第 10 章 抽样分布：统计量的幕后规律

内容提要

- 统计量的核心：统计量本身也是随机变量。“稳”（方差小）。
- 核心指标：我们希望统计量既“准”（无偏性），又“稳”（方差小）。终极谜题：为什么计算样本方差时要除以 $n-1$ ？

10.1 统计量的评判标准：无偏性

定义 10.1 (无偏性 Unbiasedness)

设 $\hat{\theta}$ 是参数 θ 的估计量。如果 $\hat{\theta}$ 的数学期望恰好等于真值 θ ，即：

$$E(\hat{\theta}) = \theta$$

则称 $\hat{\theta}$ 是 θ 的无偏估计量。

直观理解：虽然单次射击可能偏左或偏右，但平均来看，我们的准星是正对靶心的，没有系统性误差。

10.2 样本均值 \bar{X} ：天选之子

定理 10.1 (\bar{X} 的性质)

设总体 X 的均值为 μ ，方差为 σ^2 。无论总体服从什么分布，样本均值 $\bar{X} = \frac{1}{n} \sum X_i$ 满足：

- 无偏性： $E(\bar{X}) = \mu$ 。
- 收敛性： $D(\bar{X}) = \frac{\sigma^2}{n}$ 。

证明 [推导（口算级）] 1. 期望：利用期望的线性性质：

$$E(\bar{X}) = E\left(\frac{1}{n} \sum X_i\right) = \frac{1}{n} \sum E(X_i) = \frac{1}{n} \cdot n\mu = \mu$$

2. 方差：利用独立性（方差可加）：

$$D(\bar{X}) = D\left(\frac{1}{n} \sum X_i\right) = \frac{1}{n^2} \sum D(X_i) = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n}$$

笔记 [标准差 vs 标准误]

- σ (Standard Deviation): 描述单个个体的波动。
- σ/\sqrt{n} (Standard Error): 描述均值的波动。
- n 越大， \bar{X} 越稳定，这也正是大数定律的基础。

10.3 样本方差 S^2 ：为什么是 $n-1$ ？

问题 10.1 如果我们要估计总体的波动 σ^2 ，直觉告诉我们要算“平均平方误差”。但为什么定义的公式是除以 $n-1$ 而不是 n ？

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

证明 [硬核推导：揭秘贝塞尔校正 (Bessel's Correction)] 我们需要证明 $E(S^2) = \sigma^2$ 。关键在于计算 $\sum (X_i - \bar{X})^2$ 的期望。

第一步：利用恒等式展开

$$\sum (X_i - \bar{X})^2 = \sum X_i^2 - n\bar{X}^2$$

(这个恒等式类似方差公式 $D(X) = E(X^2) - (EX)^2$ ，非常重要)

第二步：利用 $E(Y^2) = D(Y) + [E(Y)]^2$ 转换期望

• 对于单个样本 X_i :

$$E(X_i^2) = D(X_i) + [E(X_i)]^2 = \sigma^2 + \mu^2$$

• 对于样本均值 \bar{X} (注意 $D(\bar{X}) = \sigma^2/n$):

$$E(\bar{X}^2) = D(\bar{X}) + [E(\bar{X})]^2 = \frac{\sigma^2}{n} + \mu^2$$


第三步：求期望并代入

$$\begin{aligned} E\left[\sum (X_i - \bar{X})^2\right] &= \sum E(X_i^2) - nE(\bar{X}^2) \\ &= n(\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) \\ &= n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2 \\ &= (n-1)\sigma^2 \end{aligned}$$

结论：如果我们除以 n ，期望就是 $\frac{n-1}{n}\sigma^2$ ，这比真实的 σ^2 偏小了（有偏）。为了把这个系数 $(n-1)$ 消掉，我们必须除以 $n-1$ ：

$$E\left(\frac{1}{n-1} \sum (X_i - \bar{X})^2\right) = \frac{1}{n-1} \cdot (n-1)\sigma^2 = \sigma^2$$

10.4 直观解释：自由度的代价

 **笔记** [为什么会“偏小”？] **1. 几何解释：** $\sum (X_i - a)^2$ 在 $a = \bar{X}$ 时取最小值。真正的方差是数据到真值 μ 的距离，而我们算的是数据到均值 \bar{X} 的距离。因为 \bar{X} 是根据这组数据“凑”出来的，它天然地比 μ 更靠近数据中心。所以 $\sum (X_i - \bar{X})^2 < \sum (X_i - \mu)^2$ 。我们低估了波动，所以要除以一个更小的数 $(n-1)$ 来把结果“拉”回来。

2. 自由度解释： 我们有 n 个独立的数据 X_1, \dots, X_n 。但在计算 S^2 时，我们用到了 \bar{X} 。这就引入了一个约束条件： $\sum (X_i - \bar{X}) = 0$ 。这导致只有 $n-1$ 个数据是“自由”变动的（最后一个数据被前 $n-1$ 个和均值锁死了）。消耗了一个自由度用来估计 μ ，所以剩下的自由度只剩 $n-1$ 。

第 11 章 假设检验的内核：决策与风险

内容提要

- 假设检验不是为了证明什么是对的，而是为了** guilty)。
- 拒绝什么是错的**。
- 本章重点：两类错误的定义与计算（必考大题）。
- 核心哲学：** 疑罪从无 ** (Innocent until proven

11.1 设立假设：立靶子的艺术

笔记 [黄金法则] 原假设 H_0 (Null Hypothesis): 代表“维持现状”、“无显著差异”、“没有效果”。备择假设 H_1 (Alternative Hypothesis): 代表“我们想证明的”、“有显著变化”、“新发现”。

判别口诀:

- 相等号 ($=, \leq, \geq$) 永远在 H_0 。
- 我们想极力证明的结论放在 H_1 。

例题 11.1 实战判别 场景 A: 某药厂宣称新药比旧药 (疗效 μ_0) 更有效。

- 潜台词: 我想证明 $\mu > \mu_0$ 。
- 设定: $H_0: \mu \leq \mu_0$ vs $H_1: \mu > \mu_0$ (单侧)。

场景 B: 检验车床切割的零件直径是否等于标准值 μ_0 。

- 潜台词: 不论太大还是太小都是次品, 我想抓出次品。
- 设定: $H_0: \mu = \mu_0$ vs $H_1: \mu \neq \mu_0$ (双侧)。

11.2 两类错误：弃真与取伪

内容提要

- 我们做出的决策 (拒绝/接受 H_0) 与事实真相 (H_0 真/假) 可能不一致。
- 这就会导致两种不同性质的错误。

表 11.1: 两类错误的混淆矩阵 (以法庭判案为例)

事实真相	我们的裁决	
	接受 H_0 (判无罪)	拒绝 H_0 (判有罪)
H_0 为真 (嫌疑人无辜)	正确 (无罪释放)	第一类错误 (Type I) (弃真: 冤枉好人)
H_0 为假 (嫌疑人有罪)	第二类错误 (Type II) (取伪: 放过坏人)	正确 (罪有应得)

笔记 [概率定义]

- 第一类错误概率 (α):

$$\alpha = P(\text{拒绝 } H_0 \mid H_0 \text{ 为真})$$

这就是我们也称之为显著性水平的东西。我们通常控制它很小 (0.05), 意味着“即使冤枉好人, 概率也不能超过 5%”。

- 第二类错误概率 (β):

$$\beta = P(\text{接受 } H_0 \mid H_0 \text{ 为假})$$

这是“漏网之鱼”的概率。

- 功效 (Power): $1 - \beta$ 。即“抓坏人一抓一个准”的能力。

问题 11.1 设总体 $X \sim N(\mu, 100)$ 。我们要检验: $H_0: \mu = 50$ vs $H_1: \mu < 50$ 。采用样本量 $n = 25$, 拒绝域定为: $\bar{x} \leq 47$ 。

1. 求犯第一类错误的概率 α 。

2. 若真实的 $\mu = 45$, 求犯第二类错误的概率 β 。

解 已知 $\sigma = 10, n = 25$, 故样本均值 \bar{X} 的分布标准差 (标准误) 为 $\sigma/\sqrt{n} = 10/5 = 2$ 。

1. 计算 α (弃真) 假设 H_0 为真, 即 $\mu = 50$ 。此时 $\bar{X} \sim N(50, 2^2)$ 。我们却落入了拒绝域 ($\bar{x} \leq 47$) 的概率:

$$\alpha = P(\bar{X} \leq 47 \mid \mu = 50)$$

标准化:

$$= P\left(\frac{\bar{X} - 50}{2} \leq \frac{47 - 50}{2}\right) = P(Z \leq -1.5) = \Phi(-1.5)$$

查表得 $\alpha = 0.0668$ 。

2. 计算 β (取伪) 假设 H_0 为假, 且真实的 $\mu = 45$ 。此时 $\bar{X} \sim N(45, 2^2)$ 。我们要计算没有拒绝 H_0 (即没有落入拒绝域, $\bar{x} > 47$) 的概率:

$$\beta = P(\bar{X} > 47 \mid \mu = 45)$$

标准化:

$$\begin{aligned} &= P\left(\frac{\bar{X} - 45}{2} > \frac{47 - 45}{2}\right) = P(Z > 1) \\ &= 1 - \Phi(1) = 1 - 0.8413 = 0.1587 \end{aligned}$$

结论: 在此规则下, 我们有 6.68% 的概率冤枉好人 (α), 有 15.87% 的概率放过坏人 (β)。

注[两难困境] 观察上图 (或想象一下):

- 想要减小 α (少冤枉好人), 就要把拒绝域的门槛定得更严 (比如 $\bar{x} \leq 45$)。
- 这样一来, 拒绝域缩小, 接受域变大, 导致 β (漏网之鱼) 必然变大。
- 唯一能同时减小 α 和 β 的方法: 增加样本量 n (让分布变瘦, 重叠面积变小)。

12.2 答案与解析

解 [1. 二维均匀分布] (1) 联合密度: 因为 X, Y 独立且服从 $U[0, a]$, 故联合密度为常数:

$$f(x, y) = f_X(x)f_Y(y) = \begin{cases} \frac{1}{a^2}, & 0 \leq x \leq a, 0 \leq y \leq a \\ 0, & \text{其他} \end{cases}$$

(2) Z 的分布: 几何法: 样本空间是边长为 a 的正方形, 面积 $S = a^2$ 。事件 $\{Z \leq z\} \Leftrightarrow \{|X - Y| \leq z\}$ 对应角线附近的条形区域。计算补集 $\{|X - Y| > z\}$ (即左上角和右下角两个小三角形) 更简单。当 $0 \leq z \leq a$ 时, 小三角形边长为 $a - z$, 总面积为 $(a - z)^2$ 。

$$F_Z(z) = P(Z \leq z) = 1 - \frac{(a - z)^2}{a^2}$$

求导得密度:

$$f_Z(z) = F'_Z(z) = \frac{2(a - z)}{a^2}, \quad (0 < z < a)$$

解 [2. 假设检验] (1) 二 (取伪); 一 (弃真)。

(2) 双侧 t 检验。

- 建立假设: $H_0: \mu = 10.5$ vs $H_1: \mu \neq 10.5$
- 统计量: $T = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} = \frac{11.08 - 10.5}{0.516/6} = \frac{0.58}{0.086} \approx 6.74$
- 拒绝域: 查表 $t_{0.025}(35) \approx 2.03$ 。
- 结论: 因为 $|T| = 6.74 > 2.03$, 故拒绝 H_0 。
- 答: 该零件长度不符合要求。

解 [3. 参数估计] 该分布实际上是指数分布的变体 (平移)。

(1) 矩估计: 计算期望: 令 $t = x(\theta - 1)$, 或直接利用指数分布 $E(Y) = 1/\lambda$ 的性质。

$$E(X) = \int_0^\infty x(\theta - 1)e^{-(\theta - 1)x} dx = \frac{1}{\theta - 1}$$

令 $E(X) = \bar{X}$, 解得: $\bar{X} = \frac{1}{\theta - 1} \Rightarrow \hat{\theta}_1 = \frac{1}{\bar{X}} + 1$ 。

(2) 极大似然估计: 似然函数 $L(\theta) = (\theta - 1)^n e^{-(\theta - 1)\sum x_i}$ 。取对数: $\ln L = n \ln(\theta - 1) - (\theta - 1)\sum x_i$ 。求导: $\frac{n}{\theta - 1} - \sum x_i = 0 \Rightarrow \hat{\theta}_2 = \frac{1}{\bar{X}} + 1$ 。

(3) R 的估计: 利用 MLE 的不变性。先求 R 的表达式:

$$R = P(X > 1) = \int_1^\infty (\theta - 1)e^{-(\theta - 1)x} dx = e^{-(\theta - 1)}$$

代入 $\hat{\theta}$:

$$\hat{R} = e^{-(\frac{1}{\bar{X}} + 1 - 1)} = e^{-1/\bar{X}}$$

解 [4. 方差运算] 32。解析: $D(X - 2Y + 5) = D(X) + (-2)^2 D(Y) + 2 \cdot 1 \cdot (-2) \text{Cov}(X, Y)$ 。常数 5 的方差为 0。
 $\text{Cov}(X, Y) = \rho \sigma_X \sigma_Y = \frac{1}{3} \cdot 2 \cdot 3 = 2$ 。原式 $= 2^2 + 4 \cdot 3^2 - 4 \cdot 2 = 4 + 36 - 8 = 32$ 。

解 [5. 无偏估计常数] $\frac{1}{2(n-1)}$ 。解析: 先看单项 $E[(X_{i+1} - X_i)^2]$ 。 X_{i+1}, X_i 独立同分布, 方差均为 σ^2 。 $D(X_{i+1} - X_i) = D(X_{i+1}) + D(X_i) = 2\sigma^2$ 。又因为 $E(X_{i+1} - X_i) = \mu - \mu = 0$ 。所以 $E[(X_{i+1} - X_i)^2] = D + E^2 = 2\sigma^2$ 。求和共有 $n - 1$ 项, 总期望为 $(n - 1)2\sigma^2$ 。要等于 σ^2 , 必须 $C \cdot 2(n - 1)\sigma^2 = \sigma^2 \Rightarrow C = \frac{1}{2(n-1)}$ 。

解 [6. 抽样分布] B。解析: $X_1 - \bar{X}$ 是正态变量的线性组合, 必为正态, 均值为 0。方差计算: $X_1 - \bar{X} = \frac{n-1}{n}X_1 - \frac{1}{n}X_2 - \cdots - \frac{1}{n}X_n$ 。利用独立性: $D = (\frac{n-1}{n})^2 \sigma^2 + (n-1)(\frac{1}{n})^2 \sigma^2 = \frac{(n-1)^2 + n-1}{n^2} \sigma^2 = \frac{n-1}{n} \sigma^2$ 。

解 [7. 概率不等式] A。解析: $AB \subset C \Rightarrow P(AB) \leq P(C)$ 。由加法公式 $P(A \cup B) = P(A) + P(B) - P(AB) \leq 1$ 。可得 $P(AB) \geq P(A) + P(B) - 1$ 。故 $P(C) \geq P(AB) \geq P(A) + P(B) - 1$ 。

解 [8. 期望计算] n/p 。解析: 这是 ** 负二项分布 ** (Negative Binomial)。可以理解为: 要打中 1 次, 平均需要 $1/p$ 发 (几何分布期望)。要打中 n 次, 因为每次试验独立, 就是 n 个几何分布之和。期望 $E(X) = n \cdot \frac{1}{p} = \frac{n}{p}$ 。

解 [9. 切比雪夫不等式] $1/12$ 。解析: 构造随机变量 $Z = X + Y$ 。 $E(Z) = -2 + 2 = 0$ 。 $D(Z) = D(X) + D(Y) +$

$2\rho\sqrt{D(X)D(Y)} = 1 + 4 + 2(-0.5)\sqrt{1 \cdot 4} = 5 - 2 = 3$ 。切比雪夫不等式: $P\{|Z - E(Z)| \geq 6\} = P\{|X + Y| \geq 6\} \leq \frac{D(Z)}{6^2} = \frac{3}{36} = \frac{1}{12}$ 。

解 [10. 高斯分布] **1.** 标准化(化繁为简)直接算 X 的积分太麻烦, 先转化为标准正态分布。令 $Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$, 则 $X - \mu = \sigma Z$ 。

$$E[|X - \mu|^3] = E[|\sigma Z|^3] = \sigma^3 E[|Z|^3]$$

2. 利用对称性写出积分 Z 的密度函数 $\phi(z) = \frac{1}{\sqrt{2\pi}}e^{-z^2/2}$ 是偶函数, $|z|^3$ 也是偶函数。所以乘积是偶函数, 积分区间可以从 $(-\infty, +\infty)$ 变为 $2 \times (0, +\infty)$ 。

$$E[|Z|^3] = \int_{-\infty}^{+\infty} |z|^3 \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz = 2 \int_0^{+\infty} z^3 \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz$$

提常数出来:

$$= \sqrt{\frac{2}{\pi}} \int_0^{+\infty} z^3 e^{-z^2/2} dz$$

3. 换元积分(凑微分) 观察到 $z^3 e^{-z^2/2} = z^2 \cdot (ze^{-z^2/2})$ 。令 $t = z^2/2$, 则 $dt = z dz$, 且 $z^2 = 2t$ 。积分限: $z \in (0, +\infty) \implies t \in (0, +\infty)$ 。

$$\int_0^{+\infty} z^2 \cdot e^{-z^2/2} \cdot z dz = \int_0^{+\infty} (2t) \cdot e^{-t} \cdot dt = 2 \int_0^{+\infty} te^{-t} dt$$

利用分部积分(或者 $\Gamma(2) = 1!$):

$$\int_0^{+\infty} te^{-t} dt = [-te^{-t}]_0^{+\infty} + \int_0^{+\infty} e^{-t} dt = 0 + 1 = 1$$

4. 回代结果

$$E[|Z|^3] = \sqrt{\frac{2}{\pi}} \cdot 2 \cdot 1 = 2\sqrt{\frac{2}{\pi}}$$

最后乘上 σ^3 :

$$E[|X - \mu|^3] = 2\sqrt{\frac{2}{\pi}} \sigma^3$$